

Redes neuronales convolucionales (CNN)

Las redes neuronales convolucionales son un tipo de red neuronal artificial diseñada específicamente para trabajar con datos que presentan una estructura espacial regular, como las imágenes digitales. A diferencia de las redes densas tradicionales, las CNN utilizan la operación de convolución, que permite analizar pequeñas regiones locales de la imagen mediante filtros o kernels que se desplazan a lo largo de ella. Gracias al uso de pesos compartidos, estas redes reducen drásticamente el número de parámetros necesarios y logran una gran eficiencia computacional. Además, las CNN aprenden representaciones jerárquicas: las primeras capas detectan características simples como bordes, esquinas o texturas, mientras que las capas más profundas combinan estas características para representar formas más complejas y finalmente objetos completos. Esta jerarquía de aprendizaje explica su enorme éxito en tareas de visión por computador frente a enfoques clásicos basados en ingeniería manual de características.

LeNet

LeNet es considerada la primera arquitectura convolucional funcional y marca el inicio del uso práctico de CNN en visión por computador. Fue propuesta a finales de los años 80 por Yann LeCun para tareas de reconocimiento óptico de caracteres, como la lectura automática de dígitos manuscritos. Su arquitectura combina capas convolucionales para la extracción de características, capas de pooling para reducir la dimensionalidad y capas totalmente conectadas para la clasificación final. Aunque hoy en día resulta muy simple, LeNet demostró por primera vez que una red podía aprender automáticamente las características relevantes directamente a partir de los píxeles de entrada, sin necesidad de diseñarlas manualmente, sentando así las bases teóricas del deep learning aplicado a imágenes.

AlexNet

AlexNet supone un punto de inflexión histórico en la visión por computador al ganar el desafío ImageNet en 2012 con una mejora muy significativa respecto a los métodos anteriores. Su principal aportación fue demostrar que redes convolucionales mucho más profundas podían entrenarse con éxito si se utilizaban los recursos y técnicas adecuadas. AlexNet introdujo el entrenamiento masivo en GPU para acelerar el cálculo, popularizó el uso de la función de activación ReLU para evitar el desvanecimiento del gradiente, incorporó dropout como técnica de regularización para reducir el sobreajuste y utilizó data augmentation de forma sistemática para aumentar artificialmente el tamaño del dataset. Este modelo estableció definitivamente que la profundidad de la red es un factor clave para mejorar el rendimiento en tareas de reconocimiento visual.

VGG

Las arquitecturas VGG profundizan en la idea de redes convolucionales profundas utilizando un diseño extremadamente homogéneo y regular. En lugar de emplear filtros grandes, VGG se basa en la repetición sistemática de convoluciones pequeñas de tamaño

3×3 apiladas, lo que permite aumentar la no linealidad del modelo y reducir el número total de parámetros. Varias convoluciones pequeñas consecutivas consiguen el mismo campo receptivo que una convolución grande, pero con mejor capacidad representativa. Además, VGG duplica progresivamente el número de filtros a medida que disminuye la resolución espacial, logrando una representación rica y jerárquica de la imagen. Aunque es computacionalmente costosa, esta arquitectura es muy valorada por la calidad de las características que aprende y se utiliza ampliamente como modelo base en transfer learning.

Inception (idea general)

La arquitectura Inception surge de la observación de que los objetos y estructuras relevantes dentro de una imagen pueden aparecer a distintas escalas. En lugar de elegir un único tamaño de filtro por capa, los módulos Inception procesan la misma entrada de forma paralela con varios tamaños de filtro (por ejemplo 1×1, 3×3, 5×5 y pooling), concatenando posteriormente todas las salidas. Esto permite que la red capture simultáneamente información local y global. Para evitar que este enfoque resulte computacionalmente inviable, se introducen convoluciones 1×1 como mecanismo de reducción de dimensionalidad antes de aplicar filtros grandes. Esta idea convierte a Inception en una arquitectura muy potente y flexible, capaz de equilibrar precisión y eficiencia.

Inception v1

Inception v1, también conocida como GoogLeNet, es la primera implementación práctica de esta idea multiescala. Introduce los módulos Inception con filtros paralelos y convoluciones 1×1 para reducir el número de canales, logrando una red profunda sin un crecimiento excesivo del coste computacional. Además, para mejorar la propagación del gradiente en una red muy profunda, Inception v1 incorpora clasificadores auxiliares conectados a capas intermedias que actúan como regularizadores y estabilizan el entrenamiento. Aunque innovadora, esta versión es compleja de diseñar y entrenar, lo que motivó las mejoras posteriores.

Inception v2 (Inception-BN)

Inception v2 mejora la versión original introduciendo de forma sistemática la normalización por lotes (Batch Normalization). Esta técnica estabiliza la distribución de las activaciones internas de la red, acelera la convergencia y reduce la sensibilidad a la inicialización de los pesos. Además, Inception v2 pone más énfasis en evitar reducciones bruscas de dimensionalidad que puedan provocar cuellos de botella de representación. En esencia, no cambia el concepto base de Inception, sino que lo hace más estable, rápido y robusto durante el entrenamiento.

Inception v3

Inception v3 introduce cambios estructurales más profundos con el objetivo de reducir todavía más el coste computacional sin sacrificar capacidad representativa. Una de sus principales aportaciones es la factorización de convoluciones grandes: por ejemplo, una convolución de 5×5 se reemplaza por dos convoluciones de 3×3 consecutivas, y las convoluciones $n \times n$ se descomponen en una convolución $1 \times n$ seguida de otra $n \times 1$. Estas transformaciones reducen el número de operaciones, mejoran la eficiencia y aumentan la no linealidad del modelo. Además, Inception v3 evita reducciones espaciales agresivas, crece en anchura en lugar de sólo en profundidad e introduce técnicas como label smoothing para reducir el sobreajuste. El resultado es una arquitectura más eficiente, estable y precisa que sus predecesoras.

Inception v4

Inception v4 representa una reorganización y simplificación del diseño de Inception v3. Mantiene muchas de las ideas introducidas anteriormente, como la factorización de convoluciones y la estructura modular, pero busca un diseño más limpio y homogéneo, estandarizando los módulos y las transiciones entre ellos. Su objetivo principal es reducir la complejidad del diseño manual y facilitar su implementación, más que introducir nuevas ideas conceptuales radicales.

Inception-ResNet

Inception-ResNet combina los módulos multiescala de Inception con las conexiones residuales de ResNet. En lugar de simplemente concatenar las salidas de los filtros paralelos, se añade una conexión de salto que suma la entrada del bloque a su salida. Esto mejora de forma significativa el flujo de gradientes y permite entrenar redes aún más profundas de manera estable. Inception-ResNet v1 y v2 difieren principalmente en profundidad y coste computacional, siendo la versión v2 más potente pero también más exigente. Estas arquitecturas demuestran que los conceptos de multiescala y aprendizaje residual son altamente complementarios.

ResNet

ResNet surge para resolver uno de los principales problemas de las redes profundas: la degradación del rendimiento cuando se añaden muchas capas. Su idea central es el aprendizaje residual, implementado mediante conexiones de salto que permiten a la red aprender la diferencia entre la entrada y la salida deseada de un bloque. Gracias a estas conexiones, el gradiente puede propagarse directamente a través de la red, evitando el desvanecimiento y permitiendo entrenar modelos con cientos de capas. ResNet demuestra que la profundidad extrema no solo es posible, sino beneficiosa, siempre que la arquitectura esté bien diseñada.

ResNeXt

ResNeXt extiende la filosofía de ResNet introduciendo el concepto de cardinalidad, que representa el número de ramas paralelas dentro de un bloque residual. En lugar de aumentar únicamente la profundidad o el ancho de la red, ResNeXt incrementa el número de caminos independientes que procesan la información, lo que mejora la capacidad representativa del modelo sin un crecimiento desproporcionado del número de parámetros. Esta estrategia resulta muy eficaz y demuestra que la diversificación de transformaciones internas es una vía poderosa para mejorar el rendimiento.

DenseNet

DenseNet lleva el concepto de conexiones internas al extremo al conectar cada capa con todas las capas siguientes dentro de un bloque denso. Esto implica que cada capa recibe directamente las características extraídas por todas las capas anteriores, lo que favorece una reutilización máxima de la información, un flujo de gradiente muy eficiente y una reducción significativa del número de parámetros. Gracias a este diseño, DenseNet logra modelos muy compactos y estables, con representaciones ricas que combinan información de bajo, medio y alto nivel.

Convoluciones separables en profundidad

Las convoluciones separables en profundidad se desarrollan para reducir el coste computacional de las CNN dividiendo la convolución estándar en dos operaciones más simples: una convolución en profundidad que filtra cada canal de entrada de forma independiente y una convolución puntual de 1×1 que combina la información de todos los canales. Esta descomposición reduce drásticamente el número de multiplicaciones y parámetros, haciendo posible ejecutar modelos potentes en entornos con recursos limitados. Arquitecturas como MobileNet, Xception y EfficientNet se basan en esta técnica para lograr un equilibrio óptimo entre precisión y eficiencia.

Segmentación semántica

La segmentación semántica consiste en asignar una etiqueta de clase a cada píxel de una imagen, lo que permite identificar no solo qué objetos aparecen, sino también la región exacta que ocupan. Este problema es más complejo que la clasificación tradicional porque requiere preservar la información espacial a lo largo de toda la red. Para resolverlo, se utilizan redes completamente convolucionales y arquitecturas encoder-decoder que extraen características globales y luego reconstruyen la resolución original mediante técnicas de upsampling, produciendo mapas de segmentación densos y coherentes.

FCN (Fully Convolutional Networks)

Las redes completamente convolucionales eliminan las capas totalmente conectadas de las CNN tradicionales y utilizan únicamente convoluciones, permitiendo procesar imágenes de cualquier tamaño y generar salidas con correspondencia espacial directa. En segmentación semántica, las FCN producen mapas de puntuaciones que indican la probabilidad de cada clase en cada posición de la imagen. Su principal ventaja es la eficiencia y la reutilización de la información espacial, aunque requieren mecanismos adicionales para recuperar la resolución perdida por pooling.

SegNet

SegNet es una arquitectura encoder-decoder diseñada específicamente para segmentación semántica. Utiliza un encoder similar a VGG para extraer características y un decoder simétrico que reconstruye la imagen mediante upsampling. Su principal aportación es el uso de max-unpooling con memoria: durante el pooling del encoder se almacenan las posiciones de los máximos, que se reutilizan en el decoder para reconstruir correctamente la estructura espacial. Esto permite segmentaciones más precisas sin un gran incremento del número de parámetros.

U-Net

U-Net introduce conexiones de salto directas entre el encoder y el decoder en cada nivel de resolución. Estas conexiones permiten que el decoder reciba no solo la información comprimida de alto nivel, sino también las características espaciales detalladas de bajo nivel. Esta combinación resulta especialmente eficaz para preservar bordes y estructuras finas, lo que hace de U-Net una arquitectura muy popular en segmentación médica y científica.

Detección de objetos

La detección de objetos consiste en identificar qué objetos aparecen en una imagen y localizar su posición mediante cajas delimitadoras. Este problema combina clasificación y regresión y requiere gestionar múltiples objetos de diferentes tamaños y posiciones. Las arquitecturas modernas equilibran precisión y eficiencia según el enfoque adoptado, distinguiéndose principalmente entre métodos de una etapa y de dos etapas.

Faster R-CNN

Faster R-CNN es un modelo de detección de dos etapas que primero genera regiones candidatas mediante una Region Proposal Network y luego clasifica y refina dichas regiones. Este enfoque logra una alta precisión gracias a su análisis detallado de cada región, aunque a costa de un mayor coste computacional. Es especialmente adecuado para aplicaciones donde la precisión es prioritaria.

YOLO

YOLO (You Only Look Once) replantea la detección de objetos como un único problema de regresión directa. Divide la imagen en una rejilla y predice simultáneamente las cajas, las probabilidades de clase y la confianza en una sola pasada por la red. Este diseño permite una velocidad extremadamente alta, lo que lo hace ideal para aplicaciones en tiempo real, aunque puede sacrificar algo de precisión respecto a métodos en dos etapas.

Segmentación de instancias y Mask R-CNN

La segmentación de instancias extiende la detección de objetos añadiendo una segmentación precisa de cada objeto individual. Mask R-CNN logra esto añadiendo una tercera rama a Faster R-CNN que genera máscaras binarias a nivel de píxel para cada región detectada, combinando así localización precisa y segmentación detallada.

Redes generativas adversariales (GAN)

Las GAN son modelos generativos compuestos por dos redes que compiten entre sí: un generador que produce imágenes sintéticas a partir de ruido y un discriminador que intenta distinguir entre imágenes reales y falsas. Este entrenamiento adversarial permite aprender la distribución de los datos, aunque presenta problemas de estabilidad y colapso de modos que han motivado múltiples variantes.

DCGAN, cGAN, Pix2Pix, CycleGAN, StyleGAN

DCGAN introduce arquitecturas convolucionales profundas y técnicas de normalización para estabilizar el entrenamiento de las GAN. Las cGAN incorporan información condicional que permite controlar lo que se genera. Pix2Pix aplica este enfoque a traducción de imagen a imagen supervisada, mientras que CycleGAN lo extiende a dominios no alineados mediante pérdidas de consistencia cíclica. StyleGAN introduce un espacio de estilos intermedio que permite un control fino de atributos visuales y genera imágenes de altísima calidad.

Redes de difusión

Las redes de difusión son modelos generativos que aprenden a revertir un proceso gradual de adición de ruido. A diferencia de las GAN, su entrenamiento es más estable y controlable, y permiten generar imágenes de gran calidad mediante un proceso iterativo de eliminación de ruido. Se han convertido en el estándar actual para generación de imágenes y modelos texto-imagen.

Transfer Learning

El transfer learning consiste en reutilizar un modelo preentrenado en una tarea nueva, aprovechando que las primeras capas capturan patrones visuales generales. Esta estrategia reduce drásticamente la necesidad de datos y recursos computacionales, y suele proporcionar mejores resultados que entrenar desde cero.

Fine Tuning

El fine tuning complementa el transfer learning permitiendo ajustar progresivamente los pesos del modelo preentrenado al nuevo dominio. Descongelando capas y entrenando con una tasa de aprendizaje baja, se adaptan las representaciones sin destruir el conocimiento previo, evitando el olvido catastrófico.

Self-supervised learning y Vision Transformers

El aprendizaje auto-supervisado entrena modelos sin necesidad de etiquetas manuales, utilizando la propia estructura de los datos como señal de supervisión. Estas representaciones se reutilizan posteriormente en tareas supervisadas mediante transfer learning. Los Vision Transformers aplican mecanismos de atención a parches de imagen tratados como secuencias, capturando dependencias globales y marcando una nueva dirección en la visión por computador moderna.